




Predicció d'Avaluació de Posicions d'Escacs

Feature Engineering i Models de Regressió Clàssics

Natan Sisoiev i Ferran Villarta

Facultat de Ciències
Universitat Autònoma de Barcelona

9 de desembre de 2025

Índex

Introducció

Dataset

Feature Engineering


Models

Resultats Finals

Discussió

Treball Futur

Referències



Índex

Introducció

Dataset

Feature Engineering


Models

Resultats Finals


Discussió

Treball Futur

Referències



Motivació del Projecte

- 
- Centipawns: mesura heurística d'avantatge (+100 = 1 peó per les Blanques)
 - Motors d'escacs utilitzen funcions d'avaluació per guiar la cerca minimax
 - **Objectiu:** Aproximar funció d'avaluació amb ML clàssic
 - **Mètrica principal:** Spearman rank correlation
 - Prioritza l'ordre correcte de posicions
 - Clau per al rendiment de motors de cerca

Índex

Introducció

Dataset

Feature Engineering


Models

Resultats Finals

Discussió


Treball Futur

Referències




Característiques del Dataset

- ~13 milions de posicions (~1GB)
- FEN + centipawn evaluation (Stockfish 11, depth 22)
- Distribució centrada a 0, lleuger avantatge Blanques
- Outliers $> \pm 1000$ centipawns ($< 5\%$)



Preprocessament

- Eliminació de mat forçat (“#”) <1.5%
- Clipping a ± 1000 centipawns
- Posicions consecutives de la mateixa partida
 - Cross-validation agrupada per partida
 - Evita filtratge de dades i dependències



Distribució d'Avaluacions





Figura: Distribució de centipawns després del preprocessament

Evolució al llarg del joc



Índex

Introducció

Dataset

Feature Engineering


Models

Resultats Finals

Discussió


Treball Futur

Referències




Feature Engineering


- FEN no pot ser processat directament per regressió
- **81 features** en 7 categories
- Calculades separatament per Blanc i Negre
- Capturen material, estructura, seguretat del rei, mobilitat, atac, control de tauler, informació de joc



Categories de Features

- 
- **Piece Info** (16): recompte, valor, control central
 - **Pawn Structure** (8): aïllats, doblats, passats, illes
 - **King Safety** (15): enroc, escut de peons, files obertes, xec
 - **Mobility** (12): moviments legals per tipus de peça
 - **Attack** (10): amenaces, peces penjades/no defensades
 - **Board Control** (15): control central, files obertes/semi-obertes, alineació torres
 - **Game Info** (5): comptador migmoviment, número de mov, fase, jugador actiu, en passant

Exemple de càlcul




- SemiOpen_Columns_White: 1
- White_Piece_Value: $5 + 3 \times 3 + 5 + 9 = 28$
- Controlled_Squares_White: 42
- Mobility_Pawn_White: 4
- White_Queen: 1


Figura: Harmon–Borgov, *The Queen's Gambit*

Correlació i Importància

- Correlació feature-objectiu feble a moderada ($|r| < 0.2$)
- Interaccions no lineals: avaluació depèn de múltiples factors combinats
- XGBRegressor top features: SemiOpen Columns, Material, Controlled Squares



Correlació entre Features



Índex

Introducció

Dataset

Feature Engineering


Models

Resultats Finals

Discussió


Treball Futur

Referències




Models avaluats

- Lineals: Ridge Regression
- Arbres: XGBRegressor
- KNN: descartat per temps de predicció
- Xarxes neuronals (MLP): rendiment comparable, confirmació de viabilitat
- SVM i SVR: costos computacionals elevats



Comparació preliminar



Model	Fit (s)	Pred. (s)	Spearman
Ridge Regression	0.148	0.012	0.520
XGBRegressor	4.140	0.103	0.595
KNN	0.075	17.188	0.373
SVR	1107	404	0.457
MLP	636	0.286	0.614

Taula: Temps i rendiment comparatiu

Índex

Introducció

Dataset

Feature Engineering


Models

Resultats Finals


Discussió

Treball Futur

Referències




Comparació Models Optimitzats




Model	Fit (s)	Pred. (s)	Spearman
XGBRegressor	558	20	0.693
Ridge Regression	2	0.2	0.570

Taula: Rendiment final

Model Predictions Across Datasets



Mètriques XGBRegressor



Índex

Introducció

Dataset

Feature Engineering


Models

Resultats Finals

Discussió


Treball Futur

Referències



Observacions Principals

- XGBRegressor: millor precisió i manteniment del rang
- Ridge: prediccions ràpides però menys precises
- KNN i MLP: confirmació de limitacions i viabilitat
- Limitacions: tàctiques complexes no capturades, posicions extremes menys precises



Índex

Introducció

Dataset

Feature Engineering


Models

Resultats Finals

Discussió


Treball Futur

Referències



Pròxims Passos

- Integració en motor d'escacs real-time
- Exploració de models deep learning més avançats
- Optimització per reduir latència de predicció



Índex

Introducció

Dataset

Feature Engineering


Models

Resultats Finals

Discussió

Treball Futur

Referències



Referències

- Ronak Badhe, *Chess Evaluations Dataset*, Kaggle Dataset, [Chess Evaluations](#)
- W. Lifferth, *Python-Chess FEN Analysis*, Kaggle Notebook, [Understanding python-chess and FEN](#)
- Wikipedia, *Forsyth–Edwards Notation*, [Forsyth–Edwards Notation](#)
- Chess Fandom, *Piece Values*, [Value](#)

